

2026.09.19 SAT / 10:00-11:30 オンライン

業務を自律化する AIエージェントを、**5日間**で形にする。

評価5項目と、OrcaRouterのルーター設計。
5日間で詰まる場所を、先に潰しておきます。

MODELS

約200モデル

1つのAPIキーで。上流と同じ単価。

FREE

無料モデル \$0

Union Alpha を含む回転式の無料枠。

CREDIT

3,000円分

参加者全員にAIクレジット。

今日渡すもの

この15分で、5日間のエージェント開発に必要な材料を持ち帰ってもらいます。

01

評価の埋め方

審査の5項目が、どこで見られるのか。
OrcaRouterのどの機能が対応するのかまで、翻訳して渡します。

02

ルーターの組み方

全体像と、自分で作るルーター（Named Router）の設定項目。
最初に決めるのは、たった3つです。

03

詰まったときの逃げ道

Discord・ドキュメント・前回参加者の記事。
5日間、詰まったら先に聞いてください。

登録と、3,000円分クレジットの受け取りは、最後にまとめてご案内します。

「業務を自律化するAIエージェント」の分解

テーマの言葉を、4つの部品に分けてみます。

モデル

判断する頭脳。
ここが差し替え可能かどうかで、5日目の伸びしろが変わります。

ツール

外部API・DB・社内システム。
エージェントが「実行する」手足です。

ループ

結果を見て次を決める繰り返し。
いつ止めるかまで設計します。

記録

誰が、何を、いくらで。
運用・改善・監査の前提になります。

「業務を自律化」 = この3つを、人からAIへ移すこと

① 判断する

何を、どのモデルで、いつ止めるか

② 実行する

外部ツール・API・社内システムを動かす

③ 記録する

誰が何をしたか、いくら使ったか

この4部品のうち、モデルと記録はOrcaRouterがそのまま引き受けます。

皆さんが集中すべきは、ツールとループ——つまり「何を作るか」です。

評価5項目と、その関係

審査では、この5項目で見られます（主催の第2回基準）。

設計で埋める — ①～④

① セキュリティ

情報漏洩や不正操作への対策が設計されているか

② コストパフォーマンス

品質と利用コストを適切に最適化できているか

③ 信頼性・堅牢性

想定外の入力やエラーでも安定して処理・復旧できるか

④ 自律性

状況を判断し、必要なツールを選んで遂行できるか

発想で埋める — ⑤

⑤ アイデア・独創性

エージェントの特性を活かした、新しい業務体験や課題解決のアイデア。

審査では「既存の作業をどれだけ置き換えたか」ではなく、「AIに何を任せたか」が見られます。

例：これまで人が判断していた「入り口」を、AIが自分で選ぶ設計にする。

自律性（④）が上がるほど、セキュリティ（①）と堅牢性（③）の要求は跳ね上がります。

人が押していたボタンをAIが押す = 事故ったときの影響が、桁違いに大きいからです。①②③④は独立した項目ではなく、連動しています。

OrcaRouterとは

OpenAI互換のAI推論ゲートウェイ —— 既存スタックの「上に乗る」1つのAPI。

日本ではFlashLabsが独占提供。Hackerプランはセルフサーバ（GitHub連携・カード登録なし）。

ONE KEY

1つのAPIキーで、約200モデル

Anthropic / OpenAI / Gemini / DeepSeek / Qwen / Grok ほか。
SDKはそのまま、base_url を変えるだけ。
(2026-09-17時点で198モデル)

PRICING

トークンの上乗せ 0%

上流プロバイダの公表単価でそのまま請求。
ルーター側のマークアップはありません。

FREE TIER

無料モデル \$0（回転式）

加えて Union Alpha を搭載。
テキスト+画像入力、262Kコンテキスト、ツール呼び出しと構造化出力に対応。

ROUTING

アダプティブ・ルーティング

リクエストごとに難易度を判定し、モデルを選びます。

FAILOVER

自動フェイルオーバー

プロバイダ障害時は別のモデルへ。サービスを止めません。

GOVERNANCE

Guardrails / Firewall

PIIマスクと監査。スコープ付きAPIキーで上限も設定できます。

モデル選定・鍵管理・コスト・統制を1か所にまとめる —— その分を「何を作るか」に使えます。

OrcaRouterの全体像

アプリから見えるのは、1つのAPIだけです。



戻り：レスポンスには「実際に選ばれたモデル」が付いてくる

ログ：リクエストは Request Logs に残り、モデル別のコストが見える

裏側で起きていることを、今日は「ルーター」「ガードレール」「ログ」の3つに分けて説明します。

モデル名の代わりに、何を書けるか

すべて同じエンドポイント・同じAPIキーで使えます。

指定のしかた	何が起きるか	向いている場面
google/gemini-2.5-flash	モデルを直指定して、そのモデルを呼ぶ	挙動を固定したい／遅延を読みたい
orcarouter/auto	リクエストごとに難易度を判定してモデルを選ぶ	まず動かす／コストを抑えたい
orcarouter/free	無料モデルのプールから選ぶ（\$0）	検証・試作
fusion / fusion-flash / -mini	用途別に最適化されたルーター	定型処理を安く・速く
Named Router（自分で作る）	候補モデルと振り分けルールを自分で定義する	設計を見せたい／本番想定
auto は「最適なモデルに落ち着く」わけではありません — 毎リクエスト判定し続けます。 だから「観察してから固定する」が正しい使い方になります（③のTipsで詳しく）。		

自分で作るルーター（Named Router）の設定項目

全部埋めなくて大丈夫です。効くのは3つ（★）。

名前 orcarouter/<名前> で呼べるようになる	候補モデル（Allowed）★ このルーターが選べるモデル。明示列挙が安全
戦略（Strategy） 難易度で振り分ける等。まずは標準のままでOK	Mundane / Hard / Default ★ 安い担当＝定型、強い担当＝判断が必要な所
Fallback（受け皿）★ 全滅時の1本。候補に入れていない別ベンダーが安全	無料モデル優先 検証中は入れる。本番は用途次第
キャッシュ考慮 長い会話・エージェントほど効きます	エスカレーション 難しい所だけ一時的に上げる。回数と支出割合で上限を
候補を絞る・受け皿を1本置く・必要な時だけ上げる —— この3つだけで、②③④の評価は別物になります。	

最初に決める3つ

この3つだけで、②③④の評価は別物になります。

01

直指定で始めるか、auto に任せるか

迷ったら auto で観察。遅延とコストを見てから固定すれば、判断の根拠が残ります。

02

候補モデルを明示で絞る

安い担当・強い担当の2〜4本。ワイルドカード指定は高額モデルまで候補に入ります。

03

Fallback（受け皿）を1本置く

候補に入れていない別ベンダーを1本。使われない限り課金は発生しません。

デモ：コンソールでNamed Routerを1つ作り、1リクエスト投げて「実際に選ばれたモデル」を確認します

残り2日で最適化するより、初日にこの3つを決めておく方が効きます。

① セキュリティ

審査で見られる観点：情報漏洩や不正操作への対策が、安全に業務利用できる設計かどうか。

審査で見られる観点

- 機密情報が外に出ないか
- AIが勝手に危険な操作をしないか
- 誰が何をしたか追えるか

OrcaRouterの機能・設計

- **Guardrails**：ルール7種 × アクション5種・入力と出力の両側
- **PII Shield**：既定は「マスク」（ブロックは明示設定時のみ・ブロック時は課金なし）
- **Agent Firewall**：inbound / response / MCP / egress
- **スコープ付きAPIキー**：予算上限・有効期限
- プロンプトと出力は保持せず、学習にも使いません

5日間の使いどころ

- 顧客データ・社内データを扱うエージェントなら、ここが設計に入っているだけで説得力が変わります
- 氏名・住所・社名は既定では検出対象外。必要ならカスタムルールで補います

前回の実測（記事）

KYAKUMAP：メール → [EMAIL]、APIキー → [ORCAROUTER_API_KEY] に置換。SSN等はモデル呼び出し前に HTTP 400 で停止（課金なし）を自ら検証
zenn.dev/iineineno03k/articles/20260815-kyakumap-sales-prep-ai

② コストパフォーマンス

審査で見られる観点：OrcaRouterを活用し、AIの品質と利用コストを適切に最適化できているか。

審査で見られる観点

- 品質を落とさずにコストを抑えられているか
- 「なんとなく安い」ではなく、根拠を示せるか

OrcaRouterの機能・設計

- アダプティブ・ルーティング（難易度で振り分け）
- キャッシュを考慮したルーティング
- 無料モデル（\$0）／上乗せ 0%
- Request Logs とモデル別レシート**で「どこにいくら使ったか」が見える

測り方（ここが差になります）

- 品質を保ったままコストを **40～70%削減**（当社調べ）
- 「削った」と言うより「**測って出せる**」方が強い。ログから根拠を出す手順を1行添えます

前回の実測（記事）

うなぎつなぎ：段階ごとにモデルを固定し、素朴な auto 比で **65.1%削減**（同一10件で比較）
KIMARI：claude-opus-5 直指定 約35.2円 → **約0.13円（約270分の1）**。記事内で「原価はすべて実測」と明記
SocraMetry（前回OrcaRouter賞）：2段階LLMで **45%削減**・OrcaRouter実請求と誤差6%以内で突合
zenn.dev/oochan/articles/96ca6eced9eb46 / zenn.dev/m_go/articles/794869d594e333 / qiita.com/jksoft/items/65f7824679ddf171a93d

③ 信頼性・堅牢性

審査で見られる観点：想定外の入力やエラーが発生しても、安定して処理・復旧できるか。

審査で見られる観点

- 想定外の入力でも落ちないか
- エラー時に復旧できるか
- **5日間で最も差がつく項目**

OrcaRouterの機能・設計

- **自動フェイルオーバー**（候補を複数持つ）
- **Fallback**=全候補ダウン時の受け皿
- レート制限は 429+Retry-After（SDKが自動リトライ）
- 難しい所だけ強いモデルへエスカレーション
- ストリーミング対応

前回の知見（そのままTips）

- OpenAI SDKは既定で max_retries=2。自前のフォールバックより先にSDKが同じモデルへ再試行します
- auto の「最安」は「最速」ではない（遅延が効く箇所は観察してから固定）
- 429は別プロバイダのモデルへ逃がすと安定します

前回の実測（記事）

Crowd Weather：auto が45.96秒 → gemini-2.5-flash-lite 固定で **2.48秒**。実測で棄却して固定へ
qiita.com/a2239154301/items/ec0dd58a85dbf4db759b / zenn.dev/jovid/articles/showgi-ai-knows-when-to-interrupt

④ 自律性

審査で見られる観点：AIが状況を判断し、必要なツールや処理を選んで遂行できるか。

審査で見られる観点

- 状況を判断して、必要なツールや処理を選んでいるか
- 「決め打ち」ではなく、自分で選ぶ設計になっているか

OrcaRouterの機能・設計

- **ツール呼び出し**（関数呼び出し）で処理を選ぶ
- **MCP連携**（スキーマ変更の検知と隔離）
- **モデル選択をコードに書かずに任せる**
- 会話がモデルを跨いで安定するセッション制御
- **OrcaReplay**：実行の記録・再生・比較

5日間の使いどころ

- 「どのモデルを使うか」をコードから追い出すのが、自律性の第一歩です
- 難所だけ強いモデルへ上げる設計が、そのまま自律性の説明資料になります

前回の実測（記事）

KIMARI：「**アプリ側がモデルを固定しない**」ことの価値（コードを直さずモデルを差し替え）
うなぎつなぎ：必要な箇所だけ明示Tierにして、モデルの「考えすぎ」を構造的に防ぐ
zenn.dev/m_go/articles/794869d594e333 / zenn.dev/oochan/articles/96ca6eced9eb46

⑤ アイデア・独創性

審査で見られる観点：エージェントの特性を活かした、新しい業務体験や課題解決か。

審査で見られる観点

- エージェントの特性を活かした、新しい業務体験か
- 既存の作業をなぞるだけになっていないか

土台が安いと、打数が増える

- 約200モデルを1つのキーで差し替え
- 無料モデルで試してから強いモデルへ
- 価格は実行時に取得できる（料金表をコードに埋め込まない）
- **5日で試せる数の多さが、独創性の母数になります**

前回の「種」（記事で読めます）

- 自律型エージェント向けオフライン支援システム
- カミワザ：ライブ単価で「この解析の推定原価」を画面表示
- SocraMetry：答えを出すのではなく、問いを出させる設計

前回の実測（記事）

自律型AIエージェント向けオフライン支援システム／カミワザ／SocraMetry
qiita.com/eyepyon/items/0665686a3a3e635b7b1d / zenn.dev/hocky3/articles/2b3b638a8d6885 / qiita.com/jksoft/items/65f7824679ddf171a93d

参加者全員に、3,000円分のAIクレジット

5日間、モデルの検証と実装にそのまま使えます。

CREDIT

クレジットの受け取り

- 専用リンクから受け取れます（次のスライドでQRをお出しします）
- カード登録は不要
- 受け取ったクレジットは、カタログ内のモデル呼び出しに使えます

FREE MODEL

今日から使える無料モデル：Union Alpha

- テキスト+画像入力／262Kコンテキスト
- ネイティブのツール呼び出しと構造化出力に対応
- 提供元は非公開（評価中の stealth モデル）
- ※能力・可用性は予告なく変わることがあります

無料モデルは回転式です。当日のラインナップはモデル一覧（/models）から確認できます。

まず無料モデルで組み、当たったところだけ強いモデルに上げる —— これが5日間の基本戦略です。

5日間の武器

詰まったときに開くもの。

Discord —— **開発サポート**

質問はここへ。5日間、詰まったら先に聞いてください。

docs —— **ドキュメント**

AIエージェントに読ませやすい形式で全文を取得できます。

観測 —— **選ばれたモデルを見る**

レスポンスから実際に使われたモデルを確認。「なぜ遅い／高い」の切り分けに。

OrcaReplay / **OrcaCode Review**

実行の記録・再生・比較 / トークン課金のAIコードレビュー。

OSSプログラム：OrcaRouterをデフォルトのゲートウェイにしたOSSプロジェクトへ、推論費の5%を還元（30以上のプロジェクトが参加）



Discord で質問する

前回参加者の記事リンクは Discord にまとめて投稿します



docs.orcarouter.ai

ドキュメントはここから（AIに読ませるのも可）

OrcaRouter賞 —— 賞金10万円

前回は EEチーム「SocraMetry」が受賞（2段階LLMで45%削減・実請求と誤差6%以内で突合）。

対象

決勝に進んだチーム（前回と同じ運用です）

評価の軸

OrcaRouterの活用度を最も重視します。「入れておくだけ」より、実測して設計に反映しているかを見ます。

前回の受賞理由：「AIに答えを出させるのではなく、問いを出させる」設計と、実測の規律を高く評価しました

①②③④の設計力を、そのまま評価します —— 5日間の積み上げが点になります。

最後に、お願いが1つ

今、この場で登録して、最初の1リクエストを投げてください。

01 登録する
GitHubでサインイン（カード登録は不要）

02 クレジットを受け取る
右のQRから3,000円分

03 1本投げる
base_url と api_key の2行を変えるだけ

```
c = OpenAI(base_url="https://api.orcarouter.ai/v1",  
           api_key="sk-orca-...")  
r = c.chat.completions.create(model="orcarouter/auto", ...)
```

①②③④は設計で、⑤は発想で。土台はこちらで用意しました。

5日間、詰まったら先に Discord で聞いてください。



3,000円分のクレジット

[www.orcarouter.ai/redeem/
AI-HACK-LOVES-ORCAROUTER](https://www.orcarouter.ai/redeem/AI-HACK-LOVES-ORCAROUTER)

